

Statistique descriptive

BTS Services Informatiques aux Organisations
Théo HUET – 2025–2026

1 Statistique à une variable

Introduction

La statistique descriptive a pour objectif de recueillir, organiser, représenter et interpréter des données. Dans cette première partie, nous étudions des séries statistiques portant sur **une seule variable**.

Les statistiques sont utilisées dans de nombreux domaines :

- contrôle qualité dans l'industrie ;
- étude de ventes ou de productions ;
- analyse économique ;
- traitement de données scientifiques ;
- enquêtes et sondages.

Exemple : une entreprise mesure le nombre de pièces produites par heure sur une machine pendant une journée.

Heure	8h	9h	10h	11h	12h	13h	14h
Pièces produites	42	38	45	40	44	39	41

L'objectif est alors :

- de résumer les données ;
- de représenter les résultats ;
- d'interpréter les performances de la machine.

1.1 Vocabulaire statistique

Définition

Population : ensemble des individus étudiés.

Individu : élément de la population.

Caractère statistique : propriété étudiée sur les individus.

Exemples

On étudie les notes obtenues par une classe de BTS lors d'un devoir.

- La population est l'ensemble des étudiants.
- Un individu est un étudiant.
- Le caractère étudié est la note obtenue.

Types de caractères

Définition

Un caractère statistique peut être :

- **qualitatif** : il décrit une qualité ou une catégorie ;
- **quantitatif** : il prend des valeurs numériques.

Un caractère quantitatif peut être :

- **discret** : les valeurs sont isolées ;
- **continu** : les valeurs appartiennent à un intervalle.

Exemples

- Couleur d'un véhicule : caractère qualitatif.
- Nombre de pièces défectueuses : caractère quantitatif discret.
- Température d'un four industriel : caractère quantitatif continu.

1.2 Effectifs et fréquences

Définition

L'**effectif** d'une valeur est le nombre de fois où cette valeur apparaît.

L'**effectif total** est la somme de tous les effectifs.

La **fréquence** d'une valeur est :

$$f_i = \frac{n_i}{N}$$

où :

- n_i est l'effectif de la valeur ;
- N est l'effectif total.

Exemples

Les notes suivantes ont été obtenues par 10 étudiants :

8 10 12 10 15 12 10 14 8 11

Note	Effectif	Fréquence
8	2	0,2
10	3	0,3
11	1	0,1
12	2	0,2
14	1	0,1
15	1	0,1
Total	10	1

1.3 Représentations graphiques

Les graphiques permettent de visualiser rapidement les données et d'interpréter une série statistique.

Diagramme en bâtons


Le diagramme en bâtons est utilisé pour les caractères quantitatifs discrets.

Exemples

Nombre de défauts observés sur des pièces mécaniques :

Nombre de défauts	Effectif
0	15
1	12
2	7
3	3

Chaque valeur est représentée par une barre verticale.



Histogramme

Définition

Un histogramme est utilisé pour représenter un caractère quantitatif continu regroupé en classes.

Exemples

Temps de réponse d'un serveur informatique :

Temps (ms)	Effectif
[0; 10[	8
[10; 20[	15
[20; 30[	12
[30; 40[	5




Diagramme circulaire


Définition

Le diagramme circulaire permet de représenter des proportions ou des pourcentages.

Exemples

Répartition des dépenses d'une entreprise :

- salaires : 50 %
- énergie : 20 %
- matériel : 15 %
- transport : 15 %



1.4 Caractéristiques de position

Les caractéristiques de position permettent de résumer la position centrale d'une série statistique.

La moyenne

Définition

La moyenne d'une série statistique est :

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

Dans le cas d'effectifs :

$$\bar{x} = \frac{n_1x_1 + n_2x_2 + \cdots + n_px_p}{N}$$

Exemples

Une machine produit les quantités suivantes :

42 38 45 40 44

La moyenne vaut :

$$\bar{x} = \frac{42 + 38 + 45 + 40 + 44}{5} = 41,8$$

La machine produit donc en moyenne environ 42 pièces par heure.

Propriété

La moyenne est sensible aux valeurs extrêmes.

Exemples

Salaires dans une entreprise :

1800 1850 1900 2000 12000

La moyenne est fortement augmentée par le très grand salaire du dirigeant.

La médiane

Définition

La médiane est la valeur qui partage la série ordonnée en deux groupes de même effectif.

Exemples

Série ordonnée :

5 7 8 9 10

La médiane est :

9

Il y a autant de valeurs avant que après la médiane.

Les quartiles

Définition

- Le premier quartile Q_1 est la plus petite valeur telle qu'au moins 25% des données lui sont inférieures ou égales.
- Le troisième quartile Q_3 est la plus petite valeur telle qu'au moins 75% des données lui sont inférieures ou égales.

Exemples

Dans une entreprise, les temps de fabrication ont pour quartiles :

$$Q_1 = 12 \text{ min} \quad Q_3 = 18 \text{ min}$$

Cela signifie que :

- 25% des fabrications durent moins de 12 minutes ;
- 75% des fabrications durent moins de 18 minutes.

1.5 Caractéristiques de dispersion

Les caractéristiques de dispersion mesurent l'étalement des données.

Étendue

Définition

L'étendue d'une série statistique est :

$$\text{Étendue} = \text{valeur maximale} - \text{valeur minimale}$$

Exemples

Série :

12 15 18 22 30

L'étendue vaut :

$$30 - 12 = 18$$

Écart interquartile

Définition

L'écart interquartile est :

$$Q_3 - Q_1$$

Propriété

L'écart interquartile est peu sensible aux valeurs extrêmes.

Variance et écart-type

Définition

La variance d'une série statistique est :

$$V = \frac{n_1(x_1 - \bar{x})^2 + \dots + n_p(x_p - \bar{x})^2}{N}$$

L'écart-type est :

$$\sigma = \sqrt{V}$$

Exemples

Deux machines produisent en moyenne 50 pièces par heure.

Machine A :

49 50 51 50

Machine B :

35 65 40 60

Les deux machines ont la même moyenne mais la machine B possède une dispersion beaucoup plus grande.

La machine A est donc plus régulière.

Propriété

Plus l'écart-type est faible, plus les données sont regroupées autour de la moyenne.

1.6 Diagramme en boîte

Définition


Le diagramme en boîte permet de représenter :

- le minimum ;
- le premier quartile ;
- la médiane ;
- le troisième quartile ;
- le maximum.

Exemples

On étudie la durée de vie (en milliers d'heures) d'un composant électronique :

- Valeur minimale : 1
- Premier quartile (Q_1) : 3
- Médiane (Me) : 5
- Troisième quartile (Q_3) : 6
- Valeur maximale : 8



Il est très utilisé en contrôle qualité ou pour comparer deux productions.

2 Statistique à deux variables

Introduction

Dans de nombreuses situations, on cherche à étudier le lien entre deux grandeurs.

Par exemple :

- la température et la consommation électrique ;
- le temps d'étude et la note obtenue ;
- la vitesse et la distance de freinage ;
- le budget publicité et le chiffre d'affaires.

L'objectif est de déterminer s'il existe une relation entre ces deux variables et, si possible, de modéliser cette relation.

Exemples

Une entreprise relève les dépenses publicitaires et le chiffre d'affaires correspondant.

Publicité (k€)	Chiffre d'affaires (k€)
2	25
4	32
6	38
8	45
10	52

On souhaite savoir si une augmentation du budget publicité entraîne une augmentation du chiffre d'affaires.

2.1 Série statistique à deux variables

Définition

Une série statistique à deux variables est une série de couples :

$$(x_i; y_i)$$

où :

- x_i représente la première variable ;
- y_i représente la seconde variable.

Exemples

On mesure la température extérieure et la consommation de glaces d'un magasin.

Température (°C)	Ventes de glaces
18	25
20	30
22	36
25	45
28	58

Chaque ligne constitue un couple statistique.

2.2 Nuage de points

Définition

Le nuage de points est la représentation graphique d'une série statistique à deux variables dans un repère.

Chaque couple $(x_i; y_i)$ est représenté par un point.

Exemples

On représente graphiquement les données :

Temps d'étude (h)	Note
1	8
2	10
3	11
4	14
5	16

Le nuage de points montre une tendance croissante : plus le temps d'étude augmente, plus la note tend à augmenter.

Interprétation d'un nuage de points

Propriété

Un nuage de points peut mettre en évidence :

- une liaison croissante ;
- une liaison décroissante ;
- l'absence de liaison.

Exemples

Liaison croissante :

Plus la température augmente, plus les ventes de glaces augmentent.

Liaison décroissante :

Plus la vitesse augmente, moins le temps de trajet est important.

Absence de liaison :

La peinture d'un étudiant n'a généralement aucun lien avec sa moyenne scolaire.

2.3 Point moyen

Définition

Le point moyen d'une série statistique à deux variables est le point : $G(\bar{x}; \bar{y})$.

où :

$$\bar{x} = \frac{x_1 + x_2 + \cdots + x_n}{n}$$

et

$$\bar{y} = \frac{y_1 + y_2 + \cdots + y_n}{n}$$

Exemples

On considère les données :

x	y
2	3
4	5
6	7
8	9

On calcule :

$$\bar{x} = \frac{2 + 4 + 6 + 8}{4} = 5$$

$$\bar{y} = \frac{3 + 5 + 7 + 9}{4} = 6$$

Le point moyen est :

$$G(5; 6)$$

Propriété

La droite d'ajustement affine passe par le point moyen.

2.4 Ajustement affine

Objectif

Lorsqu'un nuage de points présente une tendance approximativement alignée, on peut chercher une droite qui modélise cette tendance.

Définition

Un ajustement affine consiste à approcher une série statistique par une droite d'équation :

$$y = ax + b$$

où :

- a est le coefficient directeur ;
- b est l'ordonnée à l'origine.

Interprétation des coefficients

Propriété

- Si $a > 0$, la droite est croissante.
- Si $a < 0$, la droite est décroissante.
- Plus $|a|$ est grand, plus la variation est importante.

Exemples

On obtient la droite :

$$y = 2x + 5$$

Cela signifie que lorsque x augmente de 1 unité, alors y augmente en moyenne de 2 unités.

2.5 Méthode des moindres carrés

Définition

La méthode des moindres carrés permet de déterminer la droite qui minimise la somme des carrés des écarts entre les points du nuage et la droite.

En pratique, cette droite est obtenue à l'aide :

- d'une calculatrice ;
- d'un tableur ;
- d'un logiciel.

Exemples

Une entreprise relève les données suivantes :

Temps de fonctionnement (h)	Consommation (kWh)
1	12
2	15
3	19
4	22
5	26

La calculatrice donne la droite d'ajustement :

$$y = 3,5x + 8,2$$

Cette droite permet d'estimer la consommation électrique.

2.6 Interpolation et extrapolation

Définition

Interpolation : estimation d'une valeur à l'intérieur de l'intervalle étudié.

Extrapolation : estimation d'une valeur en dehors de l'intervalle étudié.

Exemples

On modélise le chiffre d'affaires d'une entreprise par :

$$y = 4x + 12$$

où :

- x représente le budget publicité ;
- y représente le chiffre d'affaires.

Pour $x = 6$:

$$y = 4 \times 6 + 12 = 36$$

On estime donc le chiffre d'affaires à 36 k.

Propriété

Les extrapolations doivent être utilisées avec prudence car le modèle peut ne plus être valable en dehors des données observées.

2.7 Coefficient de corrélation linéaire

Définition

Le coefficient de corrélation linéaire, noté r , mesure la qualité d'un ajustement affine. Il vérifie :

$$-1 \leq r \leq 1$$

Interprétation

Propriété

- Si r est proche de 1 : forte corrélation positive.
- Si r est proche de -1 : forte corrélation négative.
- Si r est proche de 0 : faible corrélation.

Exemples

$$r = 0,95$$

Le nuage de points est fortement aligné autour d'une droite croissante.
L'ajustement affine est donc pertinent.

Exemples

$$r = -0,92$$

Le nuage de points suit une tendance décroissante très marquée.

Propriété

Une corrélation importante ne signifie pas forcément qu'il existe une relation de cause à effet.

Exemples

Le nombre de glaces vendues et la température sont corrélés.
Cependant, la vente de glaces n'est pas la cause de l'augmentation de la température.